

Duale Hochschule Baden-Württemberg Mannheim

Studienarbeit

Übersetzung von Vorlesungsunterlagen in TypeScript – Theoretische Informatik III

Studiengang Informatik

Studienrichtung Angewandte Informatik

Verfasser:	Ertan Ertas und Christian Strerath
Matrikelnummer:	9390224, 4965013
Kurs:	TINF23AI2
Studiengangsleiter:	Prof. Dr. Holger Hofmann
Betreuer:	Prof. Dr. Karl Stroetmann
Bearbeitungszeitraum:	15.10.2025 - 14.04.2026

Erklärung

Wir versichern hiermit, dass wir unsere Studienarbeit mit dem Thema: „Übersetzung von Vorlesungsunterlagen in TypeScript – Theoretische Informatik III“ selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt haben.

Mannheim, 24. Februar 2026

Ertan Ertas

Kaiserslautern, 24. Februar 2026

Christian Strerath

Kurzfassung (Abstract)

Auf Deutsch

In English

Inhaltsverzeichnis

1	Einleitung	1
1.1	Problemstellung	1
1.2	Zielsetzung	2
1.3	Methodik und Abgrenzung	3
2	Theoretische Grundlagen	5
2.1	Typentheorie und Datenmodellierung	5
2.1.1	Dynamische Typisierung in Python (Duck Typing)	5
2.1.2	Statische Typisierung und Control Flow Analysis in Type-Script	6
2.1.3	Type Narrowing und Discriminated Unions	7
2.1.4	Strukturelle Typisierung (Structural Typing)	8
2.2	Realisierung von Wertsemantik in Laufzeitumgebungen	10
2.2.1	Vergleich der Implementierungsstrategien	10
2.2.2	Bewertung der Verfahren	11
2.2.3	Anforderungen an Hash-Funktionen	11
2.2.4	Strategien der Kollisionsauflösung	12
2.2.5	Erhalt der Invarianten beim Löschen (Backshifting) . . .	13
2.3	Laufzeitumgebungen und WebAssembly	15
3	Literaturverzeichnis	17
A	Anhang	18
A.1	Verzeichnis der portierten Lehrnotebooks	18

Abkürzungsverzeichnis

DHBW Duale Hochschule Baden-Württemberg

WASM WebAssembly

Abbildungsverzeichnis

1	Gegenüberstellung der Gleichheitssemantik zwischen Python und TypeScript	2
2	Control Flow Analysis: Der TypeScript-Compiler verfeinert (narrowt) den Typ basierend auf logischen Bedingungen.	6
3	Visualisierung von Separate Chaining	13
4	Visualisierung von Linear Probing	14

Tabellenverzeichnis

1	Asymptotischer Laufzeitvergleich verschiedener Datenstrukturen .	10
2	Übersicht der übersetzten Notebooks im Repository	18

List of Listings

1	Type Narrowing mittels <code>instanceof</code> und Control Flow Analysis . . .	7
2	Implizite Kompatibilität ohne explizite Implementierung	9
3	Algorithmus zur Rückverschiebung (Backshift Deletion), adaptiert nach [5, S. 302]	14

Glossar

Interoperabilität Die Fähigkeit verschiedener Systeme, Technologien oder Anwendungen, nahtlos zusammenzuarbeiten und Daten auszutauschen, ohne dass spezielle Anpassungen erforderlich sind. 16

1 Einleitung

Die Vermittlung theoretischer Informatikkonzepte profitiert maßgeblich von der praktischen Umsetzung in ausführbarem Code. An der Dualen Hochschule Baden-Württemberg (DHBW) werden Konzepte wie Tokenisierung, Parsing-Algorithmen und Automatenmodelle anhand von Python-Notebooks demonstriert. Diese Wahl ist didaktisch begründet durch die hohe Lesbarkeit von Python. In einem „compiler-nahen“ Kontext, der sich durch rekursive Datenstrukturen und strikte Zustandsübergänge auszeichnet, offenbaren sich jedoch die Grenzen einer rein dynamisch typisierten Sprache. Parallel dazu hat sich TypeScript als Industriestandard etabliert, der die Flexibilität von Skriptsprachen mit der Sicherheit statischer Typsysteme verbindet.

Diese Arbeit befasst sich mit der Übertragung dieser Lehrinhalte in das TypeScript-Ökosystem. Der Fokus liegt dabei auf einer idiomatischen Portierung, die nicht nur die Syntax übersetzt, sondern die semantischen Konzepte der formalen Sprachen durch das statische Typsystem explizit modelliert.

1.1 Problemstellung

Die Portierung algorithmischer Kerne von Python nach TypeScript stellt spezifische Anforderungen an die Modellierung der Datenstrukturen und die Fehlererkennung. Folgende Problemfelder sind hierbei zentral:

Grenzen der optionalen Typisierung in Python

Obwohl Python mit Werkzeugen wie `mypy` Möglichkeiten zur statischen Typprüfung bietet, erweisen sich diese im Kontext interaktiver Jupyter-Notebooks oft als unzureichend. In der Praxis führt das dynamische Nachladen von Modulen in der Notebook-Umgebung häufig dazu, dass der Type-Checker inkonsistente Zustände meldet oder deaktiviert werden muss. Zudem fehlt dem Python-Typsystem oft die nötige Granularität bei der Flussanalyse (Control Flow Analysis): Während TypeScript durch „Type Narrowing“ innerhalb eines `if`-Blocks den Typ einer Variable verfeinern kann, muss in Python häufig auf `cast` oder `type: ignore` zurückgegriffen werden, um Validierungsfehler zu unterdrücken. Dies untergräbt das Vertrauen in die Typsicherheit, gerade bei komplexen verschachtelten Strukturen wie abstrakten Syntaxbäumen (AST).

Divergenz der Gleichheitssemantik (Value vs. Reference Semantics)

Ein fundamentales Hindernis bei der direkten Übersetzung ist die unterschiedliche Behandlung von Objektidentität und Gleichheit. Algorithmen der theoretischen Informatik, insbesondere die Potenzmengenkonstruktion oder die Minimierung

von Automaten, basieren auf der Annahme, dass Mengen von Zuständen oder Tupel als Schlüssel in Abbildungen verwendet werden können. In Python gilt: Zwei logisch identische Tupel oder Mengen werden als gleich behandelt (Wertgleichheit) und generieren denselben Hash-Wert. In der JavaScript/TypeScript-Laufzeitumgebung hingegen basieren `Set` und `Map` bei Objekten und Arrays auf Referenzgleichheit. Zwei strukturell identische Objekte an unterschiedlichen Speicheradressen gelten als ungleich.

Abbildung 1 verdeutlicht diese Diskrepanz, die eine native Verwendung von Standard-Datenstrukturen für die genannten Algorithmen verhindert.




Abbildung 1: Gegenüberstellung der Gleichheitssemantik zwischen Python und TypeScript

Quelle: Eigene Darstellung.

Herausforderungen bei der KI-gestützten Code-Generierung

Der Einsatz von Large Language Models (LLMs) zur Unterstützung der Portierung verspricht zwar eine Beschleunigung des Entwicklungsprozesses, ist jedoch mit Risiken hinsichtlich der semantischen Korrektheit behaftet. So neigen LLMs dazu, Inhalte zu generieren, die auf den ersten Blick plausibel wirken, sich bei genauerer Betrachtung jedoch als faktisch inkorrekt erweisen, ein Phänomen, welches in der Forschung als „Halluzination“ beschrieben wird [1].

1.2 Zielsetzung

Das übergeordnete Ziel dieser Arbeit ist die Bereitstellung einer vollständig typisierten TypeScript-Implementierung der Lehrinhalte aus der Vorlesung „Theoretische Informatik III“. Das Ergebnis soll eine Codebasis sein, welche die ursprünglichen Python-Notebooks funktional ersetzt, jedoch die algorithmischen Strukturen durch das statische Typsystem formal absichert.

Konkret wird angestrebt, die von der Dozentenseite kritisierte Schwerfälligkeit

der Python-Typisierung durch eine idiomatische TypeScript-Modellierung zu ersetzen. Ziel ist es, nachzuweisen, dass komplexe Invarianten von Syntaxbäumen und Automaten durch moderne Sprachfeatures wie *Discriminated Unions* und *Control Flow Analysis* bereits zur Kompilierzeit garantiert werden können. Die Arbeit soll aufzeigen, an welchen Stellen die statische Analyse von TypeScript der dynamischen Natur von Python in Bezug auf Wartbarkeit und Fehlervermeidung überlegen ist.

Ein wesentliches technisches Teilziel ist die Konzeption und Implementierung einer spezialisierten Bibliothek, welche die Lücke zwischen der Wertsemantik von Python und der Referenzsemantik von JavaScript schließt. Es soll eine performante Lösung entwickelt werden, die echtes Hashing und strukturelle Gleichheit für beliebig verschachtelte Datenstrukturen ermöglicht, um die Algorithmen der Mengenlehre ohne semantische Brüche portieren zu können.

Des Weiteren wird eine hohe technische Interoperabilität angestrebt. Die resultierende Lösung soll plattformunabhängig auf den gängigen Betriebssystemen (Windows, macOS, Linux) ausführbar sein. Durch die Reduktion nativer Abhängigkeiten soll die Einstiegshürde für Studierende minimiert und eine konsistente Ausführungsumgebung gewährleistet werden.

Begleitend verfolgt die Arbeit das methodische Ziel, die Effektivität von Large Language Models in der Software-Modernisierung zu evaluieren. Es soll untersucht werden, inwieweit ein iterativer Prozess die Problematik von Halluzinationen bei komplexen algorithmischen Übersetzungen mitigieren kann.

1.3 Methodik und Abgrenzung

Die Durchführung der Arbeit folgt einem selektiven und adaptiven Ansatz. Der Umfang der Portierung beschränkt sich auf die nummerierten Lehrnotebooks der Vorlesung sowie deren unmittelbare technische Abhängigkeiten. Übungsnotebooks, die primär dem unbetreuten Selbststudium dienen, sind explizit vom Umfang dieser Arbeit ausgeklammert. Die Auswahl der zu übersetzenden Artefakte erfolgte in Abstimmung mit dem Betreuer und ist im Anhang (siehe Abschnitt A.1) tabellarisch aufgeführt.

Die technische Umsetzung umfasst nicht nur den algorithmischen Kern, sondern auch die notwendige Infrastruktur zur Visualisierung. Ein zentrales Entwurfsziel war hierbei die Minimierung externer Systemabhängigkeiten, um eine reibungslose Nutzung auf verschiedenen Betriebssystemen zu gewährleisten. Anstatt eine lokale Installation binärer Drittsoftware vorauszusetzen, wurde die Visualisierung durch den Einsatz portabler, direkt in die Laufzeitumgebung integrierbarer Bibliotheken realisiert. Dieser Ansatz stellt sicher, dass die Notebooks

allein durch die Bereitstellung einer *Conda*-Umgebung vollständig und ohne weitere Installationsschritte ausführbar sind.

Ein zentraler methodischer Aspekt betrifft die textuelle Aufbereitung: Die begleitenden Markdown-Erklärungen in den Notebooks wurden nicht bloß übersetzt, sondern redaktionell so überarbeitet, dass sie die TypeScript-spezifischen Konzepte eigenständig und in sich geschlossen erläutern. Auf vergleichende Referenzen zur Python-Implementierung wurde im Fließtext bewusst verzichtet, um die didaktische Eigenständigkeit der TypeScript-Version zu wahren.

Entsprechend der Anforderung an die Reproduzierbarkeit und Zugänglichkeit der Ergebnisse wird der gesamte Quellcode in einem öffentlichen Repository bereitgestellt. Die Implementierung ist unter der URL <https://github.com/cstreh/rath/formal-languages-typescript> im Ordner TypeScript verfügbar.

2 Theoretische Grundlagen

Dieses Kapitel legt das theoretische Fundament für die Transformationsstrategie. Ein besonderer Schwerpunkt liegt auf der Analyse der Typsysteme, da die Diskrepanz zwischen der dynamischen Natur von Python und der statischen Analyse von TypeScript die zentrale Motivation für die Portierung darstellt.

2.1 Typentheorie und Datenmodellierung

Ein Typsystem ist ein formales logisches System, das Programmkonstrukten Eigenschaften (Typen) zuweist, um das Programmverhalten zu klassifizieren. Nach Pierce gilt ein Programm als typsicher, wenn wohlgetypte Programme nicht in einen undefinierten Zustand geraten („well-typed programs do not go wrong“) [2, S.1ff].

In der Typentheorie wird Typsicherheit häufig durch zwei Eigenschaften charakterisiert [2, S.95ff]:

- **Progress:** Ein wohlgetypter Ausdruck ist entweder bereits ein Wert oder kann einen weiteren Auswertungsschritt durchführen.
- **Preservation:** Wenn ein wohlgetypter Ausdruck einen Auswertungsschritt macht, behält das Resultat diesen Typ bei.

2.1.1 Dynamische Typisierung in Python (Duck Typing)

Python folgt dem Paradigma der dynamischen Typisierung. Typen sind hierbei Eigenschaften von Werten (Laufzeitobjekten), nicht von Variablen. Eine Variable ist lediglich ein Name, der an ein beliebiges Objekt gebunden werden kann. Die Typprüfung erfolgt implizit zur Laufzeit: Eine Operation (z. B. `obj.method()`) ist zulässig, wenn das Objekt zum Zeitpunkt des Aufrufs über das entsprechende Attribut verfügt.

Dieses Konzept wird als **Duck Typing** bezeichnet („If it walks like a duck and quacks like a duck, it is a duck“). Während dies maximale Flexibilität und schnelle Prototypenentwicklung ermöglicht, birgt es im Kontext compiler-naher Softwarearchitekturen signifikante Risiken:

1. **Späte Fehlererkennung:** Inkonsistenzen in Datenstrukturen (z. B. ein fehlendes Feld in einem AST-Knoten) führen erst dann zu einem `AttributeError`, wenn der entsprechende Codepfad zur Laufzeit durchlaufen wird.
2. **Implizite Annahmen:** Die Struktur komplexer Objekte (z. B. „Ein Token ist ein Tupel aus Typ und Wert“) muss durch Dokumentation oder Konvention gesichert werden, da die Sprache sie nicht erzwingt.

Zwar bietet Python mit `mypy` ein Werkzeug für optionale statische Typannotationen (PEP 484), dessen Analysefähigkeit ist jedoch begrenzt. Insbesondere bei der Flussanalyse (Control Flow) kann `mypy` oft nicht automatisch deduzieren, dass ein Typ nach einer Prüfung sicher ist, was zu erzwungenen `cast`-Operationen oder `# type: ignore`-Kommentaren führt.

2.1.2 Statische Typisierung und Control Flow Analysis in TypeScript

Im Gegensatz dazu führt TypeScript eine strikte statische Typprüfung vor der Ausführung durch. Ein zentrales Unterscheidungsmerkmal zu traditionellen statischen Sprachen (wie Java) ist dabei die Fähigkeit zur **Control Flow Analysis (CFA)**. Der Compiler analysiert den logischen Fluss des Codes, um den Typ einer Variable an jeder Stelle im Code so präzise wie möglich zu bestimmen.

Dieses Verfahren wird als **Type Narrowing** bezeichnet. Aus einem breiten Typ (z. B. `string | number`) wird durch Bedingungen ein engerer Typ gefiltert [3].

Abbildung 2 visualisiert diesen Prozess: Der Compiler „versteht“ die `if`-Bedingung und garantiert im jeweiligen Zweig den korrekten Typ, ohne dass zur Laufzeit weitere Casts notwendig sind.




Abbildung 2: Control Flow Analysis: Der TypeScript-Compiler verfeinert (narrowt) den Typ basierend auf logischen Bedingungen.

Quelle: Eigene Darstellung.

2.1.3 Type Narrowing und Discriminated Unions

Eine zentrale Stärke von TypeScript ist die Fähigkeit, Typen innerhalb von Kontrollstrukturen zu verfeinern. Dieses als *Narrowing* bezeichnete Verfahren ermöglicht es dem Compiler, den Typ einer Variable in einem bestimmten Codeblock präzise einzugrenzen.

Besonders relevant ist dies bei der Verwendung von *Union Types* in Kombination mit Klassen. Der Operator `instanceof` fungiert in TypeScript als sogenannter *Type Guard*. Listing 1 illustriert dieses Prinzip anhand einer rekursiven Ausdrucksstruktur.

```
1 class Value {
2     constructor(public val: number) {}
3 }
4
5 class Add {
6     constructor(public left: Expr, public right: Expr) {}
7 }
8
9 type Expr = Value | Add;
10
11 function eval(e: Expr): number {
12     if (e instanceof Value) {
13         return e.val;
14     }
15
16     return eval(e.left) + eval(e.right);
17 }
```

Listing 1: Type Narrowing mittels `instanceof` und Control Flow Analysis

Der Code demonstriert das Zusammenspiel mehrerer TypeScript-Konzepte. Die Klassen `Value` und `Add` definieren die Struktur der Daten, wobei `Value` einen primitiven Wert hält und `Add` rekursiv auf zwei weitere Ausdrücke verweist. Der Typ `Expr` wird als Vereinigung (*Union Type*) dieser beiden Klassen definiert, sodass eine Variable dieses Typs zur Laufzeit entweder eine Instanz von `Value` oder von `Add` sein kann.

Innerhalb der Funktion `eval` dient die Prüfung mittels `instanceof` als Type Guard. Der Compiler erkennt, dass im ersten `if`-Block die Variable `e` zwingend vom Typ `Value` ist, wodurch der Zugriff auf die Eigenschaft `val` statisch erlaubt wird. Im weiteren Verlauf greift die *Control Flow Analysis*: Da der erste Pfad die Funktion durch ein `return` verlässt, schlussfolgert der Compiler für den verbleibenden Code, dass `e` nur noch vom Typ `Add` sein kann. Ein expliziter `else`-Block oder eine

erneute Prüfung sind somit überflüssig; der Zugriff auf `left` und `right` ist typsicher gewährleistet.

Dies unterscheidet sich fundamental von Python, wo ein fehlendes Attribut erst zur Laufzeit einen Fehler verursachen würde. In TypeScript garantiert das Typsystem die strukturelle Integrität der Fallunterscheidung bereits vor der Ausführung.

2.1.4 Strukturelle Typisierung (Structural Typing)

Ergänzend zum Narrowing ist die *strukturelle Typisierung* von TypeScript hervorzuheben. Im Gegensatz zu nominalen Systemen (wie Java oder C#) entscheidet nicht der Name einer Klasse oder eine explizite `implements`-Klausel über die Kompatibilität, sondern ausschließlich die Form (*Shape*) des Objekts.

Sei A der Typ des zuzuweisenden Objekts (Kandidat) und B der erwartete Zieltyp (Interface oder Klasse). Weiterhin sei p eine beliebige Eigenschaft (Property) oder Methode eines Typs. Der Typ A gilt formal als kompatibel zu (oder Subtyp von) B , notiert als $A \subseteq B$, wenn A alle Eigenschaften von B besitzt und deren Typen kovariant sind:

$$A \subseteq B \iff \forall p \in \text{properties}(B) : p \in \text{properties}(A) \wedge \text{type}_A(p) \subseteq \text{type}_B(p) \quad (1)$$

In Worten: Damit A anstelle von B verwendet werden kann, muss A mindestens alle Eigenschaften besitzen, die in B definiert sind. Zusätzliche Eigenschaften in A stören die Kompatibilität nicht.

Listing 2 verdeutlicht dieses Prinzip. Ein Interface definiert lediglich eine Anforderung an die Struktur. Jedes Objekt, das diese Anforderung erfüllt, wird vom Typsystem akzeptiert.

```

1 interface Vector2D {
2     x: number;
3     y: number;
4 }
5
6 function calculateLength(v: Vector2D): number {
7     return Math.sqrt(v.x * v.x + v.y * v.y);
8 }
9
10 class Particle {
11     constructor(
12         public x: number,
13         public y: number,
14         public velocity: number
15     ) {}
16 }
17
18 const p = new Particle(3, 4, 10);
19 const len = calculateLength(p);
20 const len2 = calculateLength({ x: 5, y: 12 });

```

Listing 2: Implizite Kompatibilität ohne explizite Implementierung

Im gezeigten Beispiel wird die Klasse `Particle` (A) als Eingabe von der Funktion `calculateLength` akzeptiert, die `Vector2D` (B) erwartet. Da eine Instanz von `Particle` die geforderten Eigenschaften `x` und `y` besitzt (und mit `velocity` sogar zusätzliche Eigenschaften), gilt die Bedingung $A \subseteq B$ als erfüllt.

Dies erleichtert die Portierung von Python-Code erheblich, da Python's *Duck Typing*-Philosophie („Wenn es wie eine Ente läuft, ist es eine Ente“) direkt auf TypeScript's Interfaces abgebildet werden kann. Ein Algorithmus, der beispielsweise erwartet, dass ein Objekt über eine `hashCode`-Methode verfügt, kann in TypeScript durch ein entsprechendes Interface typisiert werden, ohne dass die verwendeten Klassen in eine starre Vererbungshierarchie gezwungen werden müssen.

Obwohl die explizite Verwendung von `implements` für die Typkompatibilität technisch nicht erforderlich ist, wird sie in der Praxis dennoch empfohlen. Sie verlagert die Fehlererkennung von der Aufrufstelle (*Call Site*) zur Definitionsstelle (*Definition Site*). Würde in der Klasse `Particle` beispielsweise die Eigenschaft `x` versehentlich fehlen, würde der Compiler dies ohne `implements` erst beim Aufruf von `calculateLength(p)` bemängeln. Mit einer expliziten Klausel (`class Particle implements Vector2D`) wird der Fehler direkt an der Klasse markiert, was die Intention des Entwicklers dokumentiert und die Wartbarkeit erhöht.

2.2 Realisierung von Wertsemantik in Laufzeitumgebungen

Ein zentrales Problem bei der Portierung von Python nach TypeScript ist die Diskrepanz im Identitätsbegriff. Während Python für Tupel und unveränderliche Mengen (`frozenset`) automatisch *Wertsemantik* (Value Semantics) anwendet, basieren JavaScript-Container (`Set`, `Map`) bei Objekten strikt auf *Referenzsemantik*. Zwei strukturell identische Zustände eines Automaten gelten in der JavaScript-Laufzeitumgebung als ungleich, sofern sie nicht physikalisch denselben Speicherbereich belegen. Diese Problematik wurde in Abbildung 1 im Abschnitt 1.1 visualisiert.

Um die Algorithmen der theoretischen Informatik korrekt abzubilden, muss daher eine Datenstruktur implementiert werden, die Objekte anhand ihres Inhalts identifiziert. Hierfür existieren in der Informatik verschiedene algorithmische Standardverfahren.

2.2.1 Vergleich der Implementierungsstrategien

Zur Auswahl einer geeigneten Datenstruktur werden im Folgenden drei klassische Ansätze verglichen: Sortierte Arrays, Balancierte Suchbäume sowie Hash-Tabellen.

Ein zentrales Unterscheidungsmerkmal ist die benötigte Schnittstelle der Schlüsselobjekte. Vergleichsbasierte Verfahren setzen voraus, dass Schlüssel eine totale Ordnung besitzen (`Interface Comparable / compareTo`), wohingegen Hash-Verfahren lediglich die Prüfung auf Äquivalenz und die Berechnung eines Streuwertes erfordern (`Interface Equality / hashCode`).

Tabelle 1 fasst das asymptotische Laufzeitverhalten der Operationen *Suchen* und *Einfügen* zusammen. Die Angaben beziehen sich auf N Elemente in der Struktur.

Tabelle 1: Asymptotischer Laufzeitvergleich verschiedener Datenstrukturen

Algorithmus	Worst Case		Average Case	
	<i>Suche</i>	<i>Einfügen</i>	<i>Suche</i>	<i>Einfügen</i>
Geordnetes Array	$O(\log N)$	$O(N)$	$O(\log N)$	$O(N)$
Balancierter Suchbaum	$O(\log N)$	$O(\log N)$	$O(\log N)$	$O(\log N)$
Hash-Tabelle	$O(N)$	$O(N)$	$O(1)$	$O(1)$

Quelle: Eigene Darstellung in Anlehnung an [4, S. 520].

2.2.2 Bewertung der Verfahren

Die Analyse der asymptotischen Laufzeiten zeigt deutliche Unterschiede in der Eignung für generische Bibliotheken.

Geordnete Arrays ermöglichen durch die Binäre Suche zwar effiziente Lesezugriffe ($O(\log N)$) und sind extrem speichereffizient, da sie ohne Zeiger auskommen. Sie disqualifizieren sich jedoch für schreibintensive Szenarien. Sobald Mengen dynamisch wachsen, erfordert das Einfügen an einer beliebigen Stelle das Verschieben aller nachfolgenden Elemente im Speicher. Dies führt zu linearen Kosten ($O(N)$). In anwendungsnahen Szenarien, wie etwa einem Backtracking-Algorithmus zum Lösen von Sudokus, werden millionenfach Zwischenzustände in Mengen eingefügt und wieder entfernt. Ein Aufwand von $O(N)$ pro Schritt würde die Gesamtlaufzeit hier exponentiell in die Höhe treiben.

Balancierte Suchbäume garantieren zwar stabile logarithmische Laufzeiten für alle Operationen, weisen jedoch Nachteile auf technischer Ebene auf. Zum einen ist die Speicherstruktur ungünstig für moderne Hardware: Da Knoten einzeln im Heap allokiert und über Zeiger verknüpft sind, liegen logisch benachbarte Daten oft physikalisch weit verstreut. Dies führt beim Traversieren zu häufigen Cache-Misses [5, S. 301]. Zum anderen stellt die Anforderung einer totalen Ordnung (`compareTo`) eine signifikante Hürde dar. Für komplexe, verschachtelte Objekte ist es oft schwierig oder rechenintensiv, eine konsistente Totalordnung zu definieren.

Hash-Tabellen bieten mit einer amortisierten Laufzeit von $O(1)$ die theoretisch beste Performance für große, dynamische Mengen. Das Risiko von Kollisionen existiert, lässt sich durch qualitativ hochwertige Hash-Funktionen aber mitigieren. Entscheidend ist die Einfachheit: Durch den Verzicht auf komplexe Rebalancierungen und die mögliche Nutzung linearer Speicherbereiche profitieren Hash-Tabellen maximal von CPU-Caches [5, S. 301].

2.2.3 Anforderungen an Hash-Funktionen

Eine Hash-Funktion $h : D \rightarrow I$ bildet Elemente aus einer theoretisch unendlichen Domäne D (z. B. alle möglichen Zeichenketten oder Objektgraphen) auf einen endlichen Indexbereich $I = \{0, \dots, m - 1\}$ ab. Damit eine Hash-Tabelle effizient arbeitet, muss die Funktion folgende theoretische Anforderungen erfüllen:

- **Determinismus:** Für zwei identische Objekte x und y muss zwingend gelten: $x = y \implies h(x) = h(y)$. Dies ist trivial für primitive Datentypen, stellt jedoch bei rekursiven Strukturen eine Herausforderung dar. Da Standard-Sets keine definierte Iterationsreihenfolge besitzen, muss die Hash-Funktion kommutativ sein (d. h. unabhängig von der Reihenfolge der Elemente), oder die Elemente müssen vor dem Hashing in eine kanonische Ordnung gebracht werden.

- **Uniformität:** Die Wahrscheinlichkeit, dass ein beliebiger Schlüssel auf einen bestimmten Index abgebildet wird, sollte für alle Indizes gleich sein ($P(h(k) = i) \approx 1/m$). Eine ungleichmäßige Verteilung führt zu Häufungen (Clustering), was die Laufzeit der Hash-Tabelle im schlimmsten Fall auf $O(N)$ degradieren lässt [5, S. 283].
- **Effizienz:** Die Berechnung von $h(x)$ muss schnell erfolgen. In der Praxis kommen oft Verfahren wie *FNV-1a* oder *MurmurHash* zum Einsatz, die durch Bit-Operationen (XOR, Shift) und Multiplikationen mit Primzahlen eine gute Durchmischung bei geringer CPU-Last erreichen.

2.2.4 Strategien der Kollisionsauflösung

Da die Domäne D meist wesentlich größer ist als der Indexbereich I , sind Kollisionen ($h(x) = h(y)$ mit $x \neq y$) nach dem Schubfachprinzip unvermeidbar. Zur Auflösung dieser Konflikte unterscheidet die Literatur zwei Hauptklassen von Verfahren:


Separate Chaining (Verkettung)

Beim Chaining enthält jeder Slot der Hash-Tabelle einen Zeiger auf eine dynamische Datenstruktur (meist eine einfach verkettete Liste), die alle Elemente aufnimmt, die auf diesen Index hashen (siehe Abbildung 3). Der Vorteil dieses Verfahrens ist seine Robustheit: Der Füllgrad der Tabelle kann theoretisch über 100 % steigen, ohne dass die Tabelle vollständig blockiert. Der Nachteil liegt im Speicheroverhead durch die Zeiger und der schlechten Cache-Lokalität, da die Listen-Knoten verstreut im Heap liegen können.

Open Addressing (Offene Adressierung)

Bei der offenen Adressierung werden alle Elemente direkt im Array der Tabelle gespeichert. Tritt eine Kollision an Index i auf, wird algorithmisch eine alternative Position (Sondierung) bestimmt. Ein weit verbreitetes Sondierungsverfahren ist das *Lineare Sondieren* (Linear Probing), bei dem sequenziell die Positionen $i, i + 1, i + 2, \dots$ geprüft werden (siehe Abbildung 4).

Dieses Verfahren maximiert die Cache-Effizienz, da Datenblöcke sequenziell geladen werden. Es leidet jedoch unter dem Phänomen des *Primären Clusterings*: Belegte Plätze neigen dazu, zu langen Ketten zu verwachsen, was die Wahrscheinlichkeit für weitere Kollisionen in diesem Bereich erhöht und die Performance bei hohem Füllgrad signifikant verschlechtert [5, S. 293].



Legende:

Grün: Listen-Kopf (Direkter Zugriff über Bucket-Pointer).

Gelb: Listen-Rumpf (Zugriff erfordert Traversierung).

Elemente A, B und C teilen sich den Hash-Index 1.

Abbildung 3: Visualisierung von Separate Chaining


Quelle: Eigene Darstellung.

2.2.5 Erhalt der Invarianten beim Löschen (Backshifting)

Eine besondere Herausforderung bei der offenen Adressierung stellt das Entfernen von Elementen dar. Wird ein Element naiv gelöscht, entsteht eine Lücke (`null`) im Cluster. Nachfolgende Elemente, die aufgrund einer Kollision hinter dieser Lücke platziert wurden, wären bei einer erneuten Suche nicht mehr auffindbar, da der Suchalgorithmus bei der ersten Lücke abbricht.

Klassische Implementierungen verwenden daher oft „Tombstones“ (spezielle Marker für gelöschte Felder). Diese führen jedoch langfristig zu einer Verschmutzung der Tabelle und verlangsamen Fehlsuchen, da der Algorithmus über Tombstones hinwegspringen muss.

Um die Performance auch bei intensiven Modifikationen stabil zu halten, kommt in dieser Arbeit das Verfahren des **Backshift Deletion** (auch bekannt als *Robin Hood Deletion*) zum Einsatz. Listing 3 zeigt eine mögliche Implementierung.



Legende:

A: Optimal platziert (PSL=0) B, C: Verschoben (Kollision) D: Verdrängt durch Cluster

Abbildung 4: Visualisierung von Linear Probing

Quelle: Eigene Darstellung.

```

1 function deleteAtIndex(index: number): void {
2     table[index] = null;
3
4     let hole = index;
5     let scanner = (hole + 1) % capacity;
6
7     while (table[scanner] !== null) {
8         const element = table[scanner];
9         const ideal = hash(element.key);
10
11         const distToHole = (hole - ideal + capacity) % capacity;
12         const distToScanner = (scanner - ideal + capacity) % capacity;
13
14         if (distToHole < distToScanner) {
15             table[hole] = element;
16             table[scanner] = null;
17             hole = scanner;
18         }
19
20         scanner = (scanner + 1) % capacity;
21     }
22 }

```

Listing 3: Algorithmus zur Rückverschiebung (Backshift Deletion), adaptiert nach [5, S. 302]

Der Algorithmus stellt die Invariante des linearen Sondierens wieder her, indem er Lücken schließt. Die Logik lässt sich wie folgt analysieren:

- **Zeile 2:** Das Element an der übergebenen Position wird physisch entfernt. Es entsteht eine Lücke (Variable `hole`).

- **Zeile 5:** Ein zweiter Zeiger (`scanner`) beginnt unmittelbar nach der Lücke und durchläuft zyklisch den restlichen Cluster.
- **Zeile 11–12:** Hier erfolgt die Kernprüfung. Es werden zwei Distanzen berechnet: Wie weit ist die Lücke vom idealen Hash-Index des Elements entfernt (`distToHole`) und wie weit ist die aktuelle Position entfernt (`distToScanner`). Die Modulo-Arithmetik behandelt dabei den zyklischen Überlauf am Array-Ende.
- **Zeile 14:** Ist die Lücke näher an der idealen Position als der aktuelle Platz ($\text{distToHole} < \text{distToScanner}$), bedeutet dies, dass das Element ursprünglich an die Stelle der Lücke (oder davor) wollte, aber verdrängt wurde.
- **Zeile 15–17:** Das Element wird in die Lücke zurückgeschoben. Dadurch wandert die Lücke nun an die Position des Scanners. Der Prozess wiederholt sich rekursiv für die neue Lückenposition, bis das Ende des Clusters erreicht ist.

Die Terminierung des Algorithmus ist durch die Eigenschaften des Linear Probing garantiert, sofern der Füllgrad der Tabelle unter 100 % gehalten wird (typischerweise $\alpha \leq 0.75$). Ein *Cluster* ist in einer Hash-Tabelle definiert als eine zusammenhängende Sequenz von belegten Slots, die von leeren Slots (`null`) begrenzt wird. Da der `scanner`-Zeiger den Cluster ab der Lücke zyklisch durchläuft und sich nur vorwärts bewegt, muss er zwangsläufig das Ende des Clusters erreichen. Da die Tabelle nicht voll sein kann, existiert mindestens ein `null`-Feld, welches die `while`-Schleife in Zeile 7 abbricht. Ein unendlicher Loop ist somit ausgeschlossen.

Das Verfahren hält die Tabelle kompakt und eliminiert die Notwendigkeit von Tombstones vollständig. Zwar sind die Kosten einer einzelnen Löschoperation im Worst-Case höher als beim bloßen Markieren, doch wird dies durch die verbesserte Cache-Lokalität und schnellere Suchzeiten (Misses) bei moderaten Füllgraden kompensiert.

2.3 Laufzeitumgebungen und WebAssembly

Ein wesentliches Ziel bei der Bereitstellung der Projektergebnisse ist die barrierefreie Nutzung der Visualisierungskomponenten in interaktiven Umgebungen wie *Jupyter Notebooks*. Traditionell erfordert die Darstellung von Automaten-Graphen via *Graphviz* die manuelle Installation nativer Binärdateien auf dem Host-System. Insbesondere unter Windows-Umgebungen führt die notwendige Konfiguration von Systempfaden häufig zu Instabilitäten und erschwert die Reproduzierbarkeit der Forschungsergebnisse.

Um diesen „Tricky Paths“-Problematiken zu begegnen, nutzt die Visualisierungslogik WebAssembly (WASM). Dabei handelt es sich um ein binäres Instruktionsformat für eine stapelbasierte virtuelle Maschine, das als portables Zielformat für die Kompilierung von Hochsprachen wie C++ dient [6].

In dieser Arbeit wird die Bibliothek `@viz-js/viz` eingesetzt, welche den ursprünglichen C-Code von Graphviz mittels *Emscripten* zu WASM kompiliert hat. Dies ermöglicht es, die komplexen Layout-Algorithmen (wie *dot*) direkt als reguläre Abhängigkeit via `npm` zu beziehen und innerhalb der Node.js-Laufzeitumgebung des Jupyter-Kernels (*ts/ab*) auszuführen. Damit wird die geforderte Interoperabilität auf Ebene der Entwicklungsumgebung erreicht: Das System ist nach einem Standard-Setup (`conda` und `npm install`) sofort einsatzbereit, ohne dass externe Grafik-Tools auf Betriebssystemebene vorinstalliert sein müssen.

3 Literaturverzeichnis

- [1] Yilin Lu, Shurui Du und Qianwen Wang. „THE AGENTOPIA TIMES: Understanding and Mitigating Hallucinations in Multi-Agent LLM Systems via Data Journalism Gameplay“. In: *2025 IEEE Visualization and Visual Analytics (VIS)*. IEEE, 2025, S. 156–160. DOI: 10.1109/VIS60296.2025.00037.
- [2] Benjamin C. Pierce. *Types and Programming Languages*. MIT Press, 2002. ISBN: 978-0262162098.
- [3] *The TypeScript Handbook*. TypeScript Team (Microsoft). 2026. URL: <https://www.typescriptlang.org/docs/handbook/2/narrowing.html> (besucht am 08.02.2026).
- [4] Robert Sedgewick und Kevin Wayne. *Algorithmen. Algorithmen und Datenstrukturen*. Person, 2014. ISBN: 978-3-86326-758-2.
- [5] Thomas H. Cormen u. a. *Introduction to Algorithms*. 4. Aufl. MIT Press, 2022. ISBN: 978-0262046305.
- [6] Andreas Haas u. a. „Bringing the web up to speed with WebAssembly“. In: *Proceedings of the 38th ACM SIGPLAN Conference on Programming Language Design and Implementation*. PLDI 2017. Barcelona, Spain: Association for Computing Machinery, 2017, S. 185–200. ISBN: 9781450349888. DOI: 10.1145/3062341.3062363. URL: <https://doi.org/10.1145/3062341.3062363>.

A Anhang

A.1 Verzeichnis der portierten Lehrnotebooks

Die folgende Tabelle listet alle Jupyter-Notebooks auf, die im Rahmen dieser Arbeit selektiert und von Python nach TypeScript portiert wurden. Die Gliederung folgt der Kapitelstruktur der Originalvorlesung „Theoretische Informatik III“.

Tabelle 2: Übersicht der übersetzten Notebooks im Repository

Original-Kapitel	Notebook-Dateiname
Chapter 03	01-Ply-Scanning-Example.ipynb 02-Regex-Tutorial.ipynb 03-Exam-Evaluation.ipynb 04-Html2Text.ipynb
Chapter 04 & 05	01-NFA-2-DFA.ipynb 02-Test-NFA-2-DFA.ipynb 03-Regex-2-NFA.ipynb 04-Test-Regex-2-NFA.ipynb 05-DFA-2-RegExp.ipynb 06-Test-DFA-2-RegExp.ipynb 07-Minimize.ipynb 08-Test-Minimize.ipynb 09-Equivalence.ipynb 10-Test-Equivalence.ipynb
Chapter 06	01-Top-Down-Parser.ipynb 02-EBNF-Parser.ipynb
Chapter 07	01-Calculator.ipynb 02-Differentiator.ipynb 03-Interpreter.ipynb
Chapter 10	01-Conflicts.ipynb 02-Conflicts-Resolved.ipynb

Quelle: Eigene Darstellung.